

Evolução MecaniQA

Baseline e Métricas

Autor: Artur Maia Coqueiro
Douglas Renan Santos
Kayky Ribeiro Souza
Lenilson Dias Soares
Joab Nascimento Rodrigues

Agenda

O objetivo dessa apresentação é demonstrar a evolução do modelo fundacional para a Sprint 2, garantindo a integridade preditiva sem vazamento de dados, além de destacar as alterações e inclusões arquiteturais nos arquivos do repositório.

1. Modelagem Baseline e Data Leakage: Isolamento temporal com defasagens.

2. Validação e Métricas: Avaliação de erro com Time Series Split.

3. Feature Engineering: Construção de Lags e Janelas Rolantes.

4. Diferenciação dos Arquivos: Atualizações no app.py, README.md e novos artefatos ML..

5. Status Atual e Considerações Finais: Métricas do pipeline implementado.

Modelagem Baseline e Prevenção **unex** de Data Leakage

Para garantir um referencial de performance honesto e livre de Data Leakage (trapaça com dados do futuro), os modelos ingênuos (Naive) e de Médias Móveis foram refatorados para isolar o tempo.

O algoritmo utiliza o método `.shift(1)` para deslocar a série, garantindo matematicamente que a previsão do dia t utilize estritamente o valor do dia $t-1$.

A estimativa por Média Móvel de 7 dias também utiliza janelas de agregação `.rolling(window=7)` combinadas com o deslocamento cronológico, para proteger a linha do tempo.

Validação Temporal e Feature Engineering



A validação cruzada tradicional (K-Fold) foi substituída pelo método Time Series Split da biblioteca scikit-learn, a fim de respeitar a ordem cronológica do histórico durante os testes.

O bloco avaliador passou a extrair métricas vitais de erro adaptadas para a linguagem de negócios do cliente: MAE, RMSE e MAPE.

A etapa de Feature Engineering traduziu o tempo em colunas numéricas, inserindo Lags atrasados (lag_1, lag_7) e atributos estatísticos de janela rolante (rolling_mean_7, rolling_std_7).

Devido às janelas de inicialização, as primeiras 7 linhas geraram valores nulos e foram sumariamente descartadas (dropna()), resultando na redução da base de 731 para 708 registros de aquecimento válidos.

Diferenciação e Atualização dos Arquivos

Arquivo `app.py`: Manteve rigorosamente a sua funcionalidade original (sem alterações de escopo), focado apenas em ler os 731 registros, indexar as datas e preencher vazios para gerar a decomposição visual aditiva da série.

Arquivo `README.md`: Atualizado estruturalmente para refletir o uso do interpretador `py -3.14`, a exigência de instalação da biblioteca `scikit-learn` e os detalhes operacionais do novo módulo preditivo.

A nova especificação de partição do dataset no repositório estabelece uma divisão cronológica de 80% para treino e 20% para testes.

Pontos de interesse e Considerações Finais

A abordagem técnica isolada pelo método shift evitou com êxito o overfitting em séries temporais no ambiente da MecaniQA.

Através do fit no arquivo pipeline.py, a arquitetura do modelo Random Forest obteve uma taxa de Erro Médio Absoluto (MAE) equivalente a 7,04 trocas de óleo no dia predito.

As features cronologicamente alinhadas formam a base sólida que provará o valor do modelo analítico avançado contra a medição do Baseline estático.

Referências



Gestão de Código: Repositório mecaniQA-MACAPA contendo scripts (app.py, pipeline.py), Notebooks de integração e PDF de documentação.

Base de Dados Histórica: mecaniqa_dataset.xlsx (Jan/2024 a Dez/2025).

Stack Tecnológico Python: pandas, matplotlib, statsmodels, openpyxl e as novas ferramentas de modelagem da scikit-learn.